UNIWERSYTET
VIZJA

w WARSZAWIE
Kierunek INFORMATYKA

PROJEKT LABORATORYJNY NR 1

Raport nr 1

Aspekty teoretyczne i analiza danych

Wykrywanie oszustw finansowych –
klasyfikacja niezbalansowanych danych

Studia niestacjonarne, grupa SLO-3/6

Adam Unrath 53840

Termin oddania: **10.04.2026**

Repozytorium kodu (GitHub): https://github.com/AdamUnrath/fraud-detection

1. Wprowadzenie do problemu wykrywania oszustw finansowych

1.1. Kontekst i znaczenie problemu

Wykrywanie oszustw finansowych (ang. fraud detection) stanowi jedno z kluczowych wyzwań współczesnej bankowości cyfrowej i systemów płatności elektronicznych. Wraz z dynamicznym wzrostem liczby transakcji bezgotówkowych, rośnie również skala potencjalnych nadużyć według danych Nilson Report, straty związane z oszustwami kartowymi na świecie sięgnęły w 2023 roku ponad 33 miliardów dolarów USD.

Wykrywanie fraudów jest z natury problemem klasyfikacji binarnej: każda transakcja jest oznaczana jako legalna (klasa 0) lub fraudowa (klasa 1). Wyzwanie polega jednak na ekstremalnym niezbalansowaniu klas typowo mniej niż 1% wszystkich transakcji stanowi oszustwo. Ta cecha sprawia, że standardowe metryki oceny modeli, takie jak dokładność (accuracy), są całkowicie niewystarczające i mogą prowadzić do fałszywego wrażenia wysokiej skuteczności systemu.

1.2. Problem niezbalansowania klas

Niezbalansowanie klas (ang. class imbalance) to sytuacja, w której rozkład etykiet w zbiorze danych jest wysoce nierównomierny. W kontekście fraud detection oznacza to, że zbiór danych zawiera np. 99,8% transakcji legalnych i 0,2% fraudów. Model uczony bez specjalnych technik może osiągnąć 99,8% accuracy, klasyfikując wszystkie obserwacje jako klasę 0 bez wykrycia ani jednego fraudu. Taki model jest bezużyteczny z punktu widzenia praktycznego zastosowania. Z tego względu kluczowe jest stosowanie metryk uwzględniających nierównowagę klas oraz technik balansowania danych treningowych.

1.3. Analiza kosztów błędów klasyfikacji – podejście cost-sensitive

W systemach wykrywania fraudów koszty błędów są asymetryczne. False Negative (FN) oznacza sytuację, gdy model nie wykrywa fraudu koszt jest bardzo wysoki i obejmuje straty finansowe klienta i banku, utratę zaufania oraz potencjalne konsekwencje prawne. False Positive (FP) to błędne oznaczenie legalnej transakcji jako fraud koszt jest niższy, ale odczuwalny poprzez zablokowanie transakcji i niezadowolenie klienta.

Podejście cost-sensitive zakłada, że systemy fraud detection powinny być projektowane z myślą o minimalizacji liczby FN, nawet kosztem wzrostu FP co bezpośrednio przekłada się na wybór progów decyzyjnych i priorytetyzację metryki Recall dla klasy fraud.

	Przewidziano: Fraud	**Przewidziano: Legalna**
Rzeczywista: Fraud	True Positive (TP) – fraud wykryty ✓	False Negative (FN) – fraud pominięty ✗ (wysoki koszt)
Rzeczywista: Legalna	False Positive (FP) – blokada legalnej transakcji (niski koszt)	True Negative (TN) – legalna transakcja zatwierdzona ✓

Tabela 1. Macierz kosztów klasyfikacji w systemach fraud detection

2. Opis danych

2.1. Źródło i charakterystyka zbioru danych

W projekcie wykorzystałem zbiór danych Credit Card Fraud Detection dostępny publicznie na platformie Kaggle, przygotowany przez grupę badawczą Machine Learning Group z Université Libre de Bruxelles (ULB). Zbiór ten jest jednym z najczęściej stosowanych benchmarków do zadań klasyfikacji niezbalansowanej w literaturze naukowej.

Dane obejmują transakcje dokonane kartami kredytowymi przez europejskich posiadaczy kart w ciągu dwóch dni we wrześniu 2013 roku.

Cecha	Wartość
Łączna liczba transakcji	284 807
Liczba fraudów (klasa 1)	492 (~0,172%)
Liczba legalnych transakcji (klasa 0)	284 315 (~99,828%)
Współczynnik niezbalansowania	~578:1 (legalne:fraud)
Liczba cech (features)	30 (V1–V28, Time, Amount)
Zmienna docelowa	Class (0 = legalna, 1 = fraud)
Typ danych	Numeryczne (float64)
Braki danych	Brak (zbiór kompletny)

Tabela 2. Podstawowe statystyki zbioru danych Credit Card Fraud Detection

2.2. Opis cech (features)

Ze względu na wymogi poufności oraz ochronę danych osobowych, większość cech w zbiorze danych została poddana transformacji PCA (Principal Component Analysis). W efekcie zbiór zawiera następujące zmienne:

V1–V28 to wyniki transformacji PCA oryginalnych cech transakcji wartości numeryczne, anonimowe, których rzeczywiste nazwy i interpretacja nie są publicznie dostępne. Time to czas w sekundach, jaki upłynął od pierwszej transakcji w zbiorze zmienna ciągła pozwalająca analizować rozkład czasowy fraudów. Amount to kwota transakcji w EUR zmienna ciągła o prawoskośnym rozkładzie, ważna w kontekście analizy kosztowej. Class to zmienna docelowa binarna (0 = legalna, 1 = fraud), silnie niezbalansowana.

2.3. Eksploracyjna analiza danych (EDA)

W ramach analizy eksploracyjnej przeprowadziłem wizualizację rozkładu klas, kwot transakcji, rozkładu czasowego oraz korelacji cech z klasą fraud. Poniżej przedstawiłem wyniki uzyskane bezpośrednio z danych za pomocą Python/Jupyter Notebook.

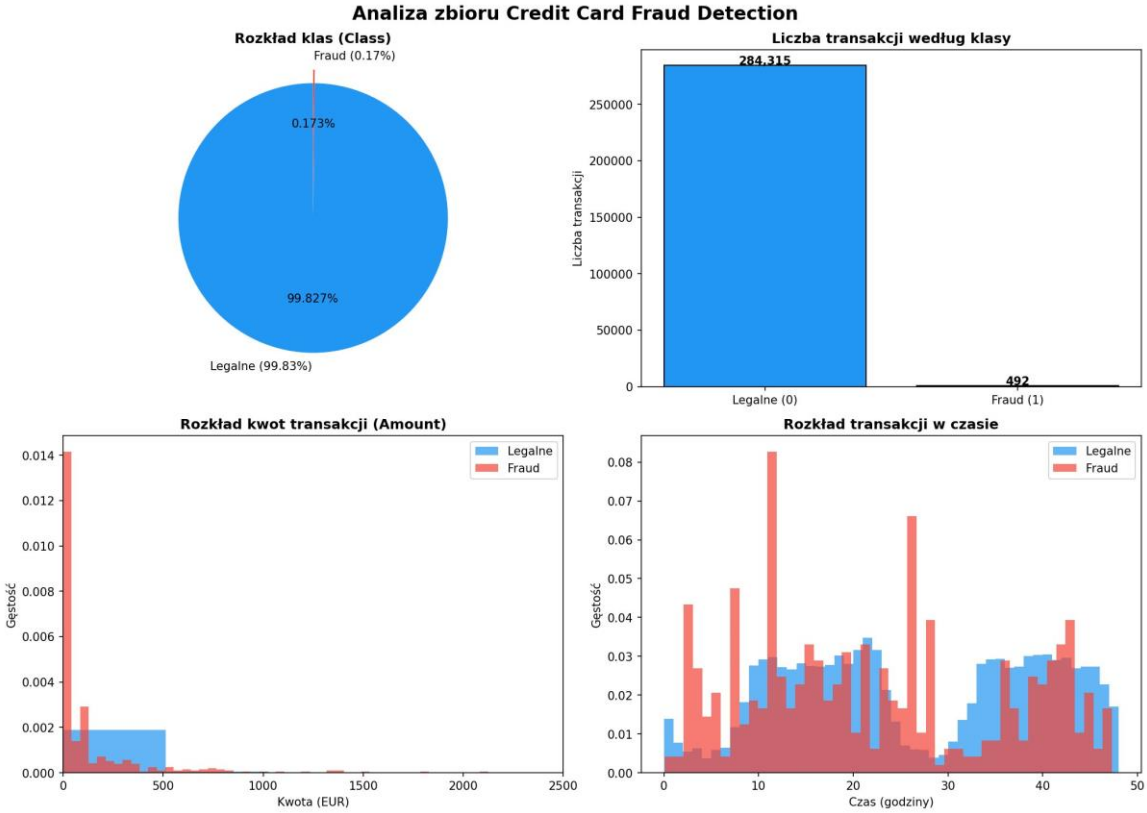

Rysunek 1. Analiza zbioru Credit Card Fraud Detection – rozkład klas, kwot i rozkład czasowy transakcji

Z przeprowadzonej analizy wynikają następujące obserwacje:

Rozkład klas: klasa 0 (legalne) stanowi 99,83% zbioru (284 315 transakcji), a klasa 1 (fraud) jedynie 0,17% (492 transakcje). Stosunek niezbalansowania wynosi ok. 578:1, co kwalifikuje ten zbiór jako przypadek ekstremalnej nierównowagi klas.

Rozkład kwot transakcji (Amount): fraudy koncentrują się przy niskich kwotach (mediana 22 EUR), podczas gdy legalne transakcje mają szerszy rozkład. Maksymalna kwota fraudu wynosi 2 125,87 EUR. Rozkład jest silnie prawoskośny, co wymaga transformacji logarytmicznej przed modelowaniem.

Rozkład w czasie (Time): zmienna Time rejestruje czas w ciągu 48 godzin obserwacji. Widoczne są dwa wyraźne szczyty aktywności transakcyjnej odpowiadające dwóm dniom, przy czym fraudy wykazują odmienny wzorzec czasowy niż transakcje legalne z charakterystycznymi spikami w godzinach nocnych.

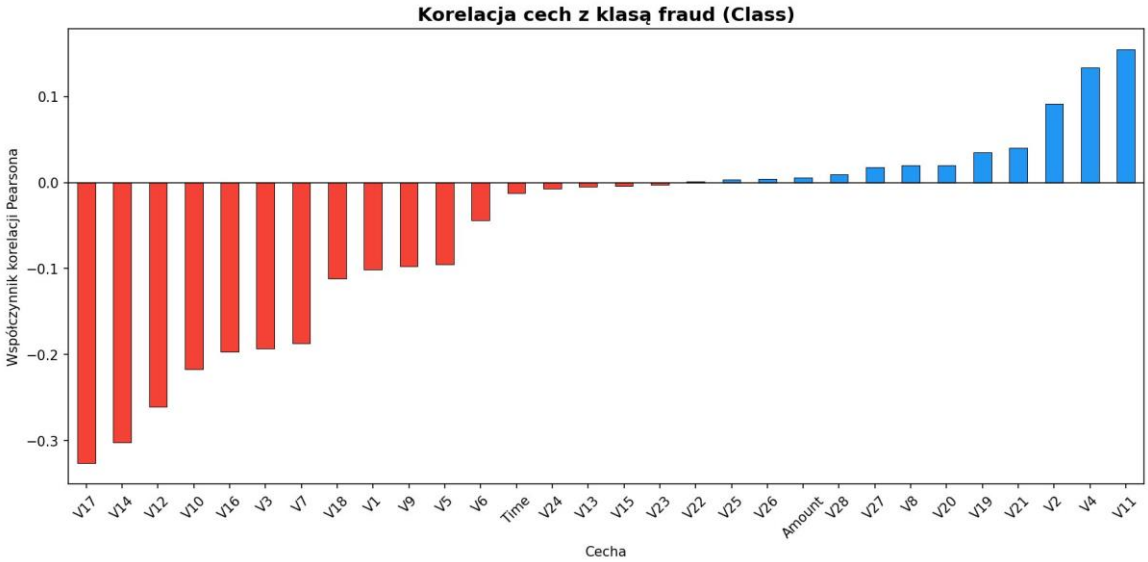

Rysunek 2. Korelacja cech V1–V28, Time i Amount z klasą fraud (Class) – współczynnik Pearsona

Analiza korelacji wskazuje, że cechy V17 i V14 mają najsilniejszą ujemną korelację z klasą fraud (odpowiednio ok. -0,33 i -0,30), natomiast V11 i V4 wykazują najsilniejszą korelację dodatnią (ok. +0,15 i +0,13). Cechy Time i Amount mają korelację bliską zeru, co sugeruje, że same w sobie nie są wystarczającymi predyktorami.

Identyfikacja ryzyk (data leakage): główne ryzyko wycieku danych wynika z potencjalnego zastosowania technik balansowania (SMOTE, oversampling) na całym zbiorze przed podziałem train/test. W projekcie techniki balansowania będę stosował wyłącznie na zbiorze treningowym. Dodatkowo, podział danych zostanie przeprowadzony z zachowaniem porządku czasowego lub stratified split.

3. Opis modeli i metod wybranych do rozwiązania

3.1. Uzasadnienie wyboru modeli klasyfikacyjnych

Wybrałem modele reprezentujące trzy różne klasy algorytmów uczenia maszynowego, co pozwoli na kompleksowe porównanie ich skuteczności w warunkach ekstremalnej nierównowagi klas.

Model	Typ	Uzasadnienie wyboru
Logistic Regression	Liniowy (baseline)	Klasyczny model bazowy, interpretowalny, szybki w uczeniu. Pozwala ocenić, czy problem jest liniowo separowalny i stanowi punkt odniesienia dla modeli złożonych.
Random Forest	Ensemble (drzewa)	Model zespołowy oparty na baggingu – odporny na overfitting, naturalnie obsługuje interakcje między cechami. Skuteczny przy niezbalansowanych danych w połączeniu z class_weight.
XGBoost	Ensemble (boosting)	Jeden z najskuteczniejszych algorytmów w konkursach ML. Obsługuje scale_pos_weight do wbudowanej obsługi niezbalansowania. Wysoka skuteczność na danych tabelarycznych.
LightGBM	Ensemble (boosting)	Szybszy alternatywny gradient boosting efektywny dla dużych zbiorów danych. Parametr is_unbalance oraz class_weight pozwalają na natywną obsługę nierównowagi.

Tabela 3. Wybrane modele klasyfikacyjne i uzasadnienie ich doboru

3.2. Metody radzenia sobie z nierównowagą klas

Wybrałem metody balansowania danych obejmujące zarówno podejścia na poziomie danych (data-level), jak i na poziomie algorytmu (algorithm-level). Brak modyfikacji stanowi punkt wyjścia (baseline) model uczony na surowych danych bez żadnych modyfikacji, pokazujący skalę problemu niezbalansowania. Class weighting polega na przypisaniu wyższych wag klasie mniejszościowej (class_weight='balanced') bezpośrednio w algorytmie, bez zmiany struktury danych. Random Oversampling to losowe powielanie próbek klasy mniejszościowej (fraud) prosta metoda, która może prowadzić do overfittingu. SMOTE (Synthetic Minority Oversampling Technique) generuje syntetyczne próbki klasy mniejszościowej na podstawie interpolacji między sąsiednimi przykładami, redukując ryzyko overfittingu. Random Undersampling polega na losowym usuwaniu próbek klasy większościowej do poziomu klasy mniejszościowej. ADASYN (Adaptive Synthetic Sampling) to adaptacyjna wersja SMOTE, generująca więcej syntetycznych przykładów w obszarach trudniejszych do klasyfikacji. Threshold moving to dostosowanie progu decyzyjnego klasyfikatora w celu zwiększenia Recall klasy fraud kosztem Precision.

3.3. Metryki ewaluacyjne

Ze względu na niezbalansowanie klas, accuracy nie jest właściwą metryką. W projekcie zastosuję następujące miary:

Metryka	Opis i znaczenie
ROC-AUC	Pole pod krzywą ROC – ocenia zdolność modelu do odróżnienia klas przy różnych progach. Wartość 0,5 = losowy model, 1,0 = idealny.
PR-AUC	Pole pod krzywą Precision-Recall – kluczowa metryka przy silnym niezbalansowaniu. Bardziej wrażliwa na skuteczność wykrywania klasy mniejszościowej niż ROC-AUC.
Recall (fraud)	Odsetek fraudów poprawnie wykrytych = TP / (TP + FN). Priorytetowa metryka z punktu widzenia minimalizacji kosztów FN.
Precision	Odsetek transakcji oznaczonych jako fraud, które rzeczywiście są fraudem = TP / (TP + FP).
F1-score	Średnia harmoniczna Precision i Recall – balansuje oba wskaźniki.
Confusion Matrix	Macierz błędów pokazująca rozkład TP, TN, FP, FN – niezbędna do analizy kosztowej.
Expected Cost	Oczekiwany koszt klasyfikacji obliczany na podstawie macierzy kosztów i wyników modelu.

Tabela 4. Metryki ewaluacyjne zastosowane w projekcie

3.4. Hipotezy badawcze

Na podstawie przeglądu literatury i analizy danych sformułowałem następujące hipotezy badawcze:

H1: Modele ensemble (Random Forest, XGBoost, LightGBM) osiągną istotnie wyższy PR-AUC niż Logistic Regression, ze względu na nieliniowy charakter granic decyzyjnych w przestrzeni cech V1–V28.

H2: Zastosowanie SMOTE lub ADASYN na zbiorze treningowym zwiększy Recall klasy fraud o co najmniej 10 punktów procentowych w porównaniu do modelu bez balansowania.

H3: Optymalizacja progu decyzyjnego (threshold tuning) pozwoli uzyskać lepszy kompromis Precision–Recall niż domyślny próg 0,5, szczególnie dla modeli boostingowych.

H4: Metody balansowania stosowane wyłącznie na zbiorze treningowym nie spowodują istotnego data leakage, a wyniki na zbiorze testowym będą wiarygodne.

Literatura

Dal Pozzolo, A., Caelen, O., Johnson, R. A., & Bontempi, G. (2015). Calibrating Probability with Undersampling for Unbalanced Classification. IEEE Symposium Series on Computational Intelligence.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.

Kaggle – Credit Card Fraud Detection Dataset: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS 2017.

Brownlee, J. (2020). Imbalanced Classification with Python. Machine Learning Mastery.

Repozytorium kodu (GitHub): https://github.com/AdamUnrath/fraud-detection